

Valoración analítica de opciones europeas bajo un modelo Heston de dos factores con cambio de régimen

Implementación, verificación y calibración a datos de mercado

Proyecto final · Métodos Numéricos en Finanzas
Maestría en Actuaría y Finanzas · Universidad Nacional de Colombia · 2026-I

Resumen. Implementamos, verificamos y calibramos el modelo de volatilidad estocástica de dos factores con cambio de régimen de Lin & He (2021), que introduce una cadena de Markov en la volatilidad de la volatilidad del modelo de Heston preservando una fórmula cerrada para opciones europeas. Reconstruimos la función característica por el procedimiento en dos etapas del artículo (función característica condicional vía Feynman–Kac y ansatz afin, seguida de la esperanza sobre la cadena de Markov mediante una exponencial matricial) y valoramos por inversión de Gil-Pelaez. Verificamos la implementación en tres niveles: degeneración exacta al modelo de Heston, validación de la integral $\int D^2$ contra cuadratura numérica, y comparación con dos simulaciones Monte Carlo independientes (Euler completo y semi-Monte-Carlo), con error relativo máximo inferior al 0.7% reportado por el artículo. Analizamos numéricamente la cuadratura de inversión y documentamos una propiedad clave: la función característica del modelo no está acotada a altas frecuencias (consecuencia de la violación de la condición de Feller), lo que exige un truncamiento cuidadoso. Finalmente calibramos el modelo y el de Heston a opciones del S&P 500 (SPY) y comparamos su ajuste dentro y fuera de muestra.

Palabras clave: volatilidad estocástica · dos factores · cambio de régimen · función característica · Gil-Pelaez · calibración.

1. Introducción

La valoración de opciones bajo el modelo de Black & Scholes (1973) supone volatilidad constante, hipótesis desmentida por la *sonrisa de volatilidad* observada en los mercados. Los modelos de volatilidad estocástica corrigen esta deficiencia; el de Heston (1993) es el más popular porque, pese a introducir un segundo factor aleatorio, admite una fórmula semianalítica para opciones europeas vía su función característica. Sin embargo, con parámetros constantes el modelo de Heston ajusta imperfectamente los datos de mercado, y existe amplia evidencia empírica de que la volatilidad cambia de *régimen* con los ciclos económicos.

Cuando la dinámica del subyacente admite una función característica en forma cerrada, el precio de una opción europea se obtiene por inversión de Fourier. Existen varias familias de métodos semianalíticos para esta inversión: la transformada rápida de Fourier de Carr–Madan, el método COS de Fang–Oosterlee, la cuadratura directa y la fórmula de inversión de Gil-Pelaez. En este trabajo usamos la inversión de Gil-Pelaez con cuadratura de Gauss-Legendre, por ser la forma en que el artículo base plantea el precio y por su transparencia numérica; los aspectos de convergencia y truncamiento se estudian en detalle en la Sección 6, siguiendo el enfoque de métodos de transformada del curso (Hirsa, 2024).

Este trabajo implementa el modelo de Lin & He (2021), que incorpora un factor de cambio de régimen —gobernado por una cadena de Markov— en la volatilidad de la volatilidad del modelo

de Heston, preservando una fórmula cerrada exacta para opciones europeas. Nuestro aporte es una implementación reproducible y verificada del método, un análisis numérico de la cuadratura de inversión (que el artículo no detalla) y una calibración a datos de mercado reales, comparando el ajuste con el modelo de Heston. El código y los detalles de reproducción acompañan a este documento.

2. El artículo base

Lin & He (2021) parten de la observación de que Heston (1993) logra una fórmula cerrada gracias a la estructura afín de su función característica, y de que trabajos previos que introducen cambio de régimen en la volatilidad de la volatilidad —notablemente He y Zhu (2016)— solo obtienen fórmulas *aproximadas* válidas para vencimientos cortos. El objetivo del artículo es construir un modelo con volatilidad de volatilidad de régimen cambiante que admita una solución cerrada *exacta*.

La dificultad central es que la introducción de la cadena de Markov hace intratable la derivación directa de la función característica. La solución es un procedimiento en dos etapas (regla de la torre): primero se obtiene la función característica *condicional* a la trayectoria de la cadena, y luego se toma la esperanza sobre la cadena. El resultado principal es una fórmula cerrada para el precio de la call europea (ec. 2.8 del artículo), con la que la calibración a datos de mercado resulta computacionalmente eficiente.

3. Marco teórico y método

3.1. El modelo

Bajo la medida neutral al riesgo, el precio del subyacente S_t y la varianza v_t siguen

$$\frac{dS_t}{S_t} = r dt + \sqrt{v_t} dW_t^1, \quad (1)$$

$$dv = k(\theta - v) dt + \sigma\sqrt{v} dW_t^2 + \lambda_{X_t} dB_t, \quad (2)$$

donde W^1, W^2 son brownianos con correlación ρ , B_t es un browniano independiente, y X_t es una cadena de Markov de dos estados, independiente de los brownianos, con tasas de transición $\lambda_{12}, \lambda_{21}$. El nivel de volatilidad de la volatilidad de régimen λ_{X_t} toma el valor λ_1 o λ_2 según el estado. Cuando $\lambda_1 = \lambda_2 = 0$ el modelo se reduce exactamente al de Heston, propiedad que usamos como prueba de verificación.

Como reconocen los autores, el término $\lambda_{X_t} dB_t$ rompe la condición de Feller: la varianza puede volverse negativa. Esto se acepta a cambio de tratabilidad analítica y mejor ajuste, al igual que en otros modelos conocidos (Stein–Stein, rough Heston). Retomamos esta propiedad en el análisis numérico (Sección 6), pues tiene una consecuencia práctica importante sobre la fórmula de inversión.

3.2. Valoración por inversión de Gil-Pelaez

Con $y_t = \ln S_t$ y $\tau = T - t$, el precio de la call europea se expresa mediante el teorema de Gil-Pelaez (Gil-Pelaez, 1951) como

$$U = e^{-r\tau} [m(-j) P_1 - K P_2], \quad (3)$$

$$P_2 = \frac{1}{2} + \frac{1}{\pi} \int_0^\infty \operatorname{Re} \left[\frac{e^{-j\varphi \ln K}}{j\varphi} m(\varphi) \right] d\varphi, \quad P_1 = \frac{1}{2} + \frac{1}{\pi} \int_0^\infty \operatorname{Re} \left[\frac{e^{-j\varphi \ln K}}{j\varphi} \frac{m(\varphi - j)}{m(-j)} \right] d\varphi, \quad (4)$$

donde $m(\varphi) = \mathbb{E}[e^{j\varphi y_T}]$ es la función característica de y_T y $m(-j) = \mathbb{E}[S_T] = S e^{(r-q)\tau}$. Incorporamos el rendimiento por dividendos q sustituyendo $r \rightarrow r - q$ en la deriva (extensión respecto del artículo original, justificada en la Sección 5).

3.3. Función característica en dos etapas

Etapas 1 (condicional). Condicionando en la trayectoria de la cadena de Markov, λ_{X_t} es una función determinista del tiempo λ_t , de modo que no se acopla un sistema de EDPs. La función característica condicional $h(\varphi|X_T) = e^{C(\varphi;\tau) + D(\varphi;\tau)v + j\varphi y}$ satisface, por el teorema de Feynman–Kac, la EDP

$$\frac{\partial h}{\partial t} + \frac{1}{2}v \frac{\partial^2 h}{\partial y^2} + \frac{1}{2}(\sigma^2 v + \lambda_t^2) \frac{\partial^2 h}{\partial v^2} + \rho \sigma v \frac{\partial^2 h}{\partial v \partial y} + \left(r - \frac{1}{2}v\right) \frac{\partial h}{\partial y} + k(\theta - v) \frac{\partial h}{\partial v} = 0, \quad (5)$$

con condición terminal $h|_{t=T} = e^{j\varphi y_T}$. Sustituyendo el ansatz afín y agrupando términos en v se obtienen dos EDOs:

$$\frac{\partial D}{\partial \tau} = \frac{1}{2}\sigma^2 D^2 + (j\varphi \rho \sigma - k)D - \frac{1}{2}(j\varphi + \varphi^2), \quad \frac{\partial C}{\partial \tau} = \frac{1}{2}\lambda_t^2 D^2 + k\theta D + rj\varphi. \quad (6)$$

La ecuación para D es una Riccati de coeficientes constantes con solución cerrada

$$D = \frac{d - a}{\sigma^2} \frac{1 - e^{d\tau}}{1 - g e^{d\tau}}, \quad a = j\varphi \rho \sigma - k, \quad d = \sqrt{a^2 + \sigma^2(j\varphi + \varphi^2)}, \quad g = \frac{a - d}{a + d}. \quad (7)$$

Integrando la EDO de C (sin el término de régimen) se obtiene la parte de Heston

$$\overline{C} = rj\varphi\tau + \frac{k\theta}{\sigma^2} \left\{ [d - a]\tau - 2 \ln \left[\frac{1 - g e^{d\tau}}{1 - g} \right] \right\}. \quad (8)$$

La componente de régimen de C es $\frac{1}{2} \int_t^T \lambda_s^2 D^2(\varphi; T - s) ds$, cuya forma cerrada se expresa mediante

$$f(\varphi; \tau) = \int_0^\tau D(\varphi; u)^2 du = \frac{1}{\sigma^4} \left\{ [d - a]^2 \tau + 4a \ln \left[\frac{1 - g e^{d\tau}}{1 - g} \right] + \frac{4d}{1 - g e^{d\tau}} - \frac{4d}{1 - g} \right\}. \quad (9)$$

Etapas 2 (incondicional). La esperanza sobre la cadena de Markov del término exponencial de régimen se calcula, siguiendo a Elliott & Lian (2013), como una exponencial matricial: $\mathbb{E} \left[e^{\frac{1}{2} \int_t^T \langle \lambda_s^2 D^2, X_s \rangle ds} \mid X_t \right] = \langle e^M X_t, I \rangle$, donde $I = (1, 1)^T$, $X_t \in \{(1, 0)^T, (0, 1)^T\}$ y

$$M = A^T \tau + \operatorname{diag} \left(\frac{1}{2} \lambda_1^2 f, \frac{1}{2} \lambda_2^2 f \right), \quad A = \begin{pmatrix} -\lambda_{12} & \lambda_{12} \\ \lambda_{21} & -\lambda_{21} \end{pmatrix}. \quad (10)$$

La función característica final es $m(\varphi) = e^{\overline{C} + Dv + j\varphi y} \langle e^M X_t, I \rangle$ (ec. 2.20). El factor de régimen es la suma de la columna de e^M correspondiente al estado actual. En la implementación calculamos e^M para la matriz 2×2 en forma cerrada por descomposición espectral, y combinamos su exponente con el de Heston en una sola exponencial por autovalor; esto evita el desbordamiento $0 \times \infty$ que

aparece en la cola de altas frecuencias (donde el factor de Heston decae mientras el de régimen crece), problema al que volvemos en la Sección 6.

Nota sobre erratas del artículo. Al transcribir las fórmulas detectamos y verificamos numéricamente dos erratas tipográficas del texto original: (i) la entrada $(2, 2)$ de la matriz explícita M aparece como $-\lambda_{21}$ sin el factor τ , cuando la derivación $\int A^T ds = A^T \tau$ implica $-\lambda_{21} \tau$ (usamos esta última); (ii) las ecuaciones (2.16) y (2.20) escriben la unidad imaginaria como i en vez de j . Ninguna afecta la implementación una vez corregidas.

4. Datos

Calibramos a opciones sobre el S&P 500. El artículo usa opciones europeas del índice (SPX) de 2011; su fuente comercial exacta no es replicable públicamente. Utilizamos en cambio un snapshot público reciente obtenido con `yfinance`.

Elección del subyacente. Un snapshot de opciones del índice $\hat{\text{SPX}}$ tomado fuera del horario de mercado presenta cotizaciones bid/ask válidas casi exclusivamente para calls dentro del dinero, lo que impide una calibración representativa. Optamos por opciones de **SPY** (el ETF del S&P 500), con liquidez amplia en todo el rango de moneyness. La contrapartida es que las opciones de SPY son americanas; para calls de corto plazo (30–90 días) sobre un subyacente de bajo rendimiento por dividendos, la prima de ejercicio anticipado es despreciable y la valoración europea es una buena aproximación (limitación que señalamos en la discusión).

Filtros (siguiendo al artículo, Sección 4.1): vencimientos entre 30 y 90 días; moneyness $|S - K|/K < 10\%$; precio de mercado igual al punto medio bid-ask; se descartan cotizaciones vacías. La tasa libre de riesgo es el T-Bill a 13 semanas ($\hat{\text{IRX}}$), análogo al T-Bill de 3 meses del artículo.

Dividendos. Estimamos el rendimiento por dividendos q por vencimiento a partir de la paridad put-call (forward implícito F del par call-put más cercano a ATM, y $q = r - \frac{\ln(\frac{F}{S})}{\tau}$). Este enfoque es autocontenido y consistente con los precios observados.

Métrica	Valor
spot_S	751.28
tasa_r	0.0369
q_min	-0.0121
q_max	0.0029
n_contratos	650
n_vencimientos	6
dias_min	31
dias_max	85
strikes_min	683
strikes_max	834
n_OTM	197
n_ATM	252
n_ITM	201

Tabla 1: Resumen del conjunto de datos de mercado (SPY) tras aplicar los filtros del artículo.

La Figura 1 muestra la superficie de volatilidad implícita del conjunto limpio. Se observa el *skew* característico de los índices de renta variable: la volatilidad implícita decrece con el strike (mayor para opciones dentro del dinero, es decir, con K bajo) y el nivel general varía con el vencimiento. Esta estructura —que Black–Scholes no puede reproducir con una única volatilidad— es precisamente la que los modelos de volatilidad estocástica buscan capturar, y por tanto un banco de prueba adecuado para la calibración.




Figura 1: Volatilidad implícita frente al moneyness $\frac{K}{S}$ por vencimiento (SPY, datos limpios). El *skew* decreciente en el strike es la firma que los modelos de volatilidad estocástica pretenden ajustar.

5. Implementación, verificación y calibración

5.1. Implementación

La implementación está en Python (biblioteca `rsheston`), con separación entre la lógica de valoración (funciones características y cuadratura de Gil-Pelaez), la simulación Monte Carlo, el pipeline de datos y la calibración. La integral de inversión se evalúa por cuadratura de Gauss-Legendre truncada. La exponencial de la matriz 2×2 se calcula en forma cerrada (descomposición espectral) y vectorizada sobre las frecuencias, evitando cientos de llamadas a una rutina genérica de exponencial matricial por cada precio, lo que es esencial para la eficiencia de la calibración.

5.2. Verificación

Verificamos la implementación en múltiples niveles independientes:

1. **Degeneración a Heston.** Con $\lambda_1 = \lambda_2 = 0$, el precio del modelo coincide con el de Heston hasta el error de cuadratura, y con $\sigma \rightarrow 0$, $v_0 = \theta$, el de Heston coincide con Black-Scholes. La Figura 2 muestra la transición al variar un factor de escala z sobre λ_1, λ_2 .
2. **Validación de $f(\varphi; \tau)$.** La forma cerrada de $\int_0^\tau D^2$ (ec. 2.19) coincide con su integración numérica directa a tolerancia 10^{-8} .
3. **Monte Carlo.** Comparamos la fórmula cerrada contra dos simulaciones independientes. La primera es una simulación de Euler completa del sistema acoplado (S, v, X_t) bajo truncamiento de la varianza en cero (necesario porque el modelo viola Feller); es una verificación totalmente independiente de la fórmula, a costa de mayor varianza. La segunda es la *semi-Monte-Carlo* del artículo: se simula únicamente la trayectoria de la cadena de Markov (con tiempos de permanencia exponenciales) y, dado el camino, el precio condicional se obtiene con la función característica condicional por Gil-Pelaez; el precio final es el promedio de los precios condicionales sobre los caminos. Este segundo método tiene varianza mucho menor y valida específicamente el paso de la esperanza matricial de Elliott-Lian (ec. 2.17), que es el más propenso a error. La Figura 3 y la Tabla 2 resumen el acuerdo: el error relativo máximo respecto de la semi-Monte-Carlo es del orden de $10^{-3}\%$, holgadamente inferior al 0.7% del artículo.




Figura 2: Degeneración al modelo de Heston: al escalar $\lambda_1 = 0.3z$, $\lambda_2 = 0.2z$, el precio del modelo se acerca al de Heston y coincide exactamente en $z = 0$.




Figura 3: Fórmula cerrada frente a Monte Carlo (semi-MC y Euler completo) a lo largo del precio del subyacente, y error relativo frente a la cota del 0.7% del artículo.

S	Fórmula	semi-MC	err.est.	Euler-MC	err.rel.(%)
8.000000	0.118209	0.118209	0.000000	0.116807	0.000314
8.500000	0.224308	0.224309	0.000001	0.222016	0.000340
9.000000	0.382055	0.382057	0.000001	0.379354	0.000508
9.500000	0.596145	0.596148	0.000002	0.593594	0.000460
10.000000	0.866289	0.866292	0.000002	0.863522	0.000338
10.500000	1.188047	1.188049	0.000002	1.184999	0.000212
11.000000	1.554331	1.554333	0.000001	1.551096	0.000110
11.500000	1.956971	1.956972	0.000000	1.953399	0.000038
12.000000	2.387943	2.387943	0.000000	2.384142	0.000006

Tabla 2: Precios de la fórmula cerrada vs Monte Carlo y error relativo (parámetros de la Fig. 1 del artículo).

5.3. Calibración

Calibramos minimizando el error cuadrático medio en dólares entre precios de mercado y de modelo (ec. 4.1 del artículo),

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (C_i^{\text{mercado}} - C_i^{\text{modelo}})^2, \quad (11)$$

con optimización global (`scipy.optimize.dual_annealing`, análogo abierto al *adaptive simulated annealing* del artículo), pues el objetivo no es convexo. Calibramos con datos in-sample y evaluamos también fuera de muestra. Las cotas de los parámetros, la semilla y el optimizador se reportan en el código para reproducibilidad.

La Tabla 3 presenta los parámetros estimados; la Tabla 4, los errores dentro y fuera de muestra; y la Tabla 5, el desglose por moneyness (análogos a las Tablas 1–3 del artículo).

Parámetro	Heston	Lin & He
kappa	5.1474	5.1461
theta	0.0483	0.0482
sigma	1.2552	1.2535
rho	-0.6226	-0.6229
v0	0.0171	0.0171
lambda1		0.0000
lambda2		0.0000
lambda12		5.0000
lambda21		5.0000

Tabla 3: Parámetros estimados (in-sample) para ambos modelos.

Modelo	MSE in-sample	MSE out-of-sample
Heston	0.0435	0.1886
Lin-He	0.0435	0.1885

Tabla 4: Errores cuadráticos medios dentro y fuera de muestra.

Modelo	OTM	ATM	ITM
Heston	0.0260	0.0476	0.5370
Lin-He	0.0257	0.0476	0.5371

Tabla 5: Errores fuera de muestra por moneyness.




Figura 4: Ajuste de la calibración: precios de mercado vs precios de ambos modelos calibrados para el vencimiento más corto (in-sample). Las curvas de Heston y Lin & He se superponen.

6. Discusión: análisis numérico y comparación

6.1. Convergencia y truncamiento de la cuadratura

La cuadratura de Gauss-Legendre converge rápidamente en el número de nodos (Figura 5). El aspecto más delicado es el truncamiento superior de la integral. A diferencia de una función característica genuina, acotada por 1 en módulo, la función característica *formal* de este modelo no está acotada: como consecuencia de la violación de la condición de Feller, el término de régimen $\frac{1}{2}\lambda^2 f(\varphi; \tau)$ crece cuadráticamente en φ y, aunque el módulo $|m(\varphi)|$ decae a frecuencias moderadas, eventualmente *explota* en la cola (Figura 6). En consecuencia, un truncamiento fijo demasiado grande contamina el precio (Figura 7).

Resolvemos esto con un truncamiento *adaptativo* que ubica el límite superior en la región de decaimiento, antes de la explosión. Para los parámetros calibrados (con λ pequeño) la explosión ocurre a frecuencias tan altas que el módulo ya es despreciable, y el precio es estable para

cualquier truncamiento razonable; el fenómeno solo es relevante para valores grandes de λ . Este comportamiento, que el artículo no discute, es una limitación numérica inherente al modelo y está directamente ligado a la violación de Feller.




Figura 5: Convergencia del precio frente al número de nodos de Gauss-Legendre.




Figura 6: Izquierda: $|m(\varphi)|$ decae y luego explota en la cola (violación de Feller). Derecha: el precio es estable en una meseta de truncamiento y se corrompe si se trunca en la región de explosión; el truncamiento adaptativo lo evita.

Figura 7:

6.2. Costo computacional

La disponibilidad de la fórmula cerrada hace la valoración órdenes de magnitud más rápida que la simulación, lo que es esencial para la calibración (miles de evaluaciones del objetivo). El costo por precio se reporta en `results/tables/04_costo_computacional.csv`.

6.3. Comparación con el artículo

Los parámetros de Heston que estimamos (Tabla 3) son del mismo orden que los del artículo (su Tabla 1): reversion $k \approx 5.1$ (artículo 8.7), nivel $\theta \approx 0.048$ (artículo 0.082), volatilidad de volatilidad

$\sigma \approx 1.26$ (artículo 1.41) y correlación $\rho \approx -0.62$ (artículo -0.31). Las diferencias son esperables: usamos SPY en 2026 en vez de SPX en 2011, un único corte transversal en lugar de seis meses de datos, y un optimizador distinto.

El resultado más relevante es que, en nuestra calibración, **el modelo de Lin & He no mejora al de Heston**: el optimizador lleva $\lambda_1, \lambda_2 \rightarrow 0$, con lo que el modelo se reduce exactamente a Heston y ambos alcanzan el mismo MSE (Tabla 4), con curvas de precio indistinguibles (Figura 4). Esto contrasta con el artículo, donde el modelo de Lin & He reduce el MSE en torno a un 45% respecto de Heston.

La explicación es metodológica y, entendemos, instructiva. El artículo calibra un **único** conjunto de parámetros a un **panel** de seis meses de cotizaciones (miércoles para estimar, jueves para validar). En ese contexto, un solo Heston debe servir a muchos estados de mercado distintos a lo largo del tiempo, y el factor de cambio de régimen aporta la flexibilidad para capturar esa variación temporal. En cambio, nuestra calibración usa un **solo corte transversal** (la superficie de un día): un único Heston ya ajusta bien esa sonrisa (MSE in-sample de 0.043 sobre 325 opciones), y no hay variación de régimen entre fechas que capturar, de modo que el segundo factor es innecesario y no está identificado. En otras palabras, la ventaja del cambio de régimen es un fenómeno de **serie temporal**, no de **corte transversal**, y nuestra limitación de datos (un solo snapshot) impide reproducir la mejora reportada.

7. Conclusiones

Implementamos y verificamos la fórmula cerrada de Lin & He (2021) para opciones europeas bajo un modelo de Heston de dos factores con cambio de régimen, y la calibramos a datos de mercado. Las verificaciones (degeneración a Heston, validación de la integral, y dos Monte Carlo independientes) confirman la corrección de la implementación. El principal hallazgo numérico propio es que la función característica del modelo no está acotada a altas frecuencias —consecuencia directa de la violación de la condición de Feller— lo que exige un truncamiento cuidadoso de la integral de inversión, aspecto no discutido en el artículo original.

En el estudio empírico, sobre un único corte transversal de opciones de SPY el modelo de Lin & He se reduce a Heston ($\lambda \rightarrow 0$) y no mejora el ajuste, a diferencia del artículo. Atribuimos esto a que la ventaja del cambio de régimen se manifiesta a lo largo del tiempo (en un panel multi-fecha) y no dentro de una sola superficie. Las extensiones naturales son, por tanto: calibrar a un **panel** de varias fechas (que requeriría una fuente de datos históricos de opciones, no disponible vía la API en vivo usada aquí); calibrar además el modelo de Elliott–Lian como tercer competidor, como en el artículo; y tratar explícitamente el ejercicio americano de las opciones de SPY. Estas direcciones permitirían una comparación más fiel con los resultados originales.

Declaración de uso de IA. Este trabajo se apoyó en herramientas de IA (asistente de programación) para la implementación, la depuración y la redacción. La responsabilidad intelectual y la comprensión de los resultados son de los autores.

Referencias

- Black, F., & Scholes, M. (1973). The Pricing of Options and Corporate Liabilities. *The Journal of Political Economy*, 81(3), 637-654.
- Elliott, R. J., & Lian, G.-H. (2013). Pricing Variance and Volatility Swaps in a Stochastic Volatility Model with Regime Switching: Discrete Observations Case. *Quantitative Finance*, 13(5), 687-698.
- Gil-Pelaez, J. (1951). Note on the Inversion Theorem. *Biometrika*, 38(3-4), 481-482.
- Heston, S. L. (1993). A Closed-Form Solution for Options with Stochastic Volatility with Applications to Bond and Currency Options. *Review of Financial Studies*, 6(2), 327-343.
- Hirsa, A. (2024). *Computational Methods in Finance* (2.^a ed.). CRC Press (Taylor & Francis Group).
- Lin, S., & He, X.-J. (2021). Analytically Pricing European Options under a New Two-Factor Heston Model with Regime Switching. *Computational Economics*. <https://doi.org/10.1007/s10614-021-10117-6>

8. Anexo A: fragmentos de código clave

Extractos del paquete `rsheston` (implementación completa reproducible en el repositorio; ver `README.md` para el mapa script $\rightarrow$ figura/tabla).

Función característica del modelo (forma estable, `charfn.py`).

```
def linhe_cf(phi, *, S, tau, r, params, state=1, q=0.0):
    a, d, g, edt = heston_core(phi, tau, params.kappa, params.theta,
                                params.sigma, params.rho)
    D = heston_D(a, d, g, edt, params.sigma)
    Cbar = heston_Cbar(a, d, g, edt, tau, params.kappa, params.theta, params.sigma)
    f = linhe_f(a, d, g, edt, tau, params.sigma)
    M11, M12, M21, M22 = linhe_M_entries(f, tau, params)
    half_T = 0.5 * (M11 + M22); delta = 0.5 * (M11 - M22)
    s = np.sqrt(delta**2 + M12 * M21)          # autovalores  $\mu_{\pm} = T/2 \pm s$ 
    num = (delta + M21) if state == 1 else (M12 - delta)
    H = Cbar + (r - q) * 1j * phi * tau + D * params.v0 + 1j * phi * np.log(S)
    beta = num / s
    # Combinación estable (evita  $0 \cdot \infty$  en la cola): un exp por autovalor.
    return 0.5*(1+beta)*np.exp(H + half_T + s) + 0.5*(1-beta)*np.exp(H + half_T - s)
```

Inversión de Gil-Pelaez con truncamiento adaptativo (`pricing.py`).

```
def gil_pelaez_call(cf, S, K, r, tau, q=0.0, u_max=200.0, n_nodes=256, adaptive=True):
    if adaptive:
        u_max = adaptive_truncation(cf, u_cap=u_max)    # trunca en la región de
decaimiento
        x, w = _leggauss_cached(n_nodes)
        phi = 0.5 * u_max * (x + 1.0); weights = 0.5 * u_max * w
        m_neg_j = S * np.exp((r - q) * tau)            # =  $E[S_T]$ , evita la singularidad
    en -j
        kernel = np.exp(-1j * phi * np.log(K)) / (1j * phi)
        P2 = 0.5 + np.sum(weights * np.real(kernel * cf(phi))) / np.pi
        P1 = 0.5 + np.sum(weights * np.real(kernel * cf(phi - 1j) / m_neg_j)) / np.pi
    return float(np.real(np.exp(-r * tau) * (m_neg_j * P1 - K * P2)))
```